

T.C.
İSTANBUL MEDENİYET ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

GÖRÜNTÜ İŞLEME VE DERİN ÖĞRENME TABANLI
HAVA DURUMU SINIFLANDIRMA SİSTEMİ
(Weather-Classification-CNN)

Hazırlayan:
Hayrunnisa Toymuş

İSTANBUL - 2025

1. GİRİŞ VE PROJENİN AMACI

1.1. Projenin Tanımı

Bu proje, son yıllarda yapay zeka alanında büyük ivme kazanan 'Bilgisayarlı Görü (Computer Vision)' ve 'Derin Öğrenme (Deep Learning)' tekniklerinin birleşiminden oluşmaktadır. Projenin temel amacı, dış ortamdan elde edilen dijital görüntülerin analiz edilerek, o anki hava durumunun (Güneşli, Yağmurlu, Bulutlu veya Gündoğumu) insan müdahalesi olmaksızın, otomatik ve yüksek doğrulukla tespit edilmesini sağlayan akıllı bir model geliştirmektir. Sistem, Konvolüsyonel Sinir Ağları (CNN) mimarisini kullanarak görüntülerdeki renk, doku, ışık yoğunluğu ve nesne desenlerini matematiksel veriye dönüştürmekte ve sınıflandırma yapmaktadır.

1.2. Seçilme Gerekçesi ve İlgili Alanın Önemi

Günümüzde hava durumu takibi, geleneksel olarak geniş alanları kapsayan uydular, radarlar ve meteorolojik istasyonlar aracılığıyla yapılmaktadır. Ancak bu sistemler, belirli bir sokağın veya caddenin anlık durumunu gösteren 'hiper-lokal' veriyi sağlamakta yetersiz kalabilmektedir. Görsel veriye dayalı hava durumu analizi, özellikle Akıllı Şehir (Smart City) uygulamaları için kritik bir boşluğu doldurmaktadır.

Özellikle otonom sürüş teknolojilerinde, araçların güvenli seyrüsefer yapabilmesi için sadece yol şeritlerini tanıması yeterli değildir; yolun kaygan olup olmadığını, sis durumunu veya parlak güneş ışığının görüşü etkileyip etkilemediğini algılaması hayati önem taşır. Bu proje sayesinde, mevcut şehir güvenlik kameraları (CCTV) kullanılarak ekstra pahalı sensör maliyetine katlanmadan, trafik sinyalizasyonunun hava koşullarına göre otomatik optimize edilmesi mümkün hale gelmektedir.

1.3. Literatür Özeti

Hava durumu sınıflandırması üzerine literatürde yapılan geçmiş çalışmalar incelendiğinde, genellikle renk histogramları, kenar belirleme ve doku analizi gibi geleneksel görüntü işleme yöntemlerinin kullanıldığı görülmüştür. Ancak bu yöntemler, gökyüzü renginin günün saatine göre değişmesi veya karmaşık arka planlar (binalar, ağaçlar) nedeniyle düşük başarı oranlarında kalmıştır.

Güncel akademik çalışmalarda ise derin öğrenme tabanlı modellerin, özellikle CNN mimarilerinin, öznetelik çıkarımındaki başarısı nedeniyle standart haline geldiği gözlemlenmiştir. Geleneksel yöntemlerin aksine CNN, görüntüyü bir bütün olarak değil, pikseller arasındaki mekansal ilişkiyi koruyarak analiz eder. Bu proje de literatürdeki bu modern yaklaşımı temel alarak, yüksek performanslı bir sınıflandırma modeli sunmayı hedeflemektedir.

2. VERİ SETİ VE ÖN İŞLEME

2.1. Veri Kaynağı ve Özellikleri

Modelin eğitimi için Kaggle platformunda bulunan ve akademik çalışmalarda yaygın olarak referans alınan 'Multi-class Weather Dataset' tercih edilmiştir. Veri seti, farklı atmosfer koşullarını, çeşitli ışık seviyelerini ve farklı kamera açılarını içeren binlerce etiketli görüntüden oluşmaktadır. Veri seti dört ana sınıfa ayrılmıştır: Cloudy (Bulutlu), Rain (Yağmurlu), Shine (Güneşli) ve Sunrise (Gündoğumu). Modelin 'overfitting' (ezberleme) yapmasını engellemek ve genelleme yeteneğini artırmak amacıyla, her sınıf için dengeli sayıda görüntü kullanılmasına özen gösterilmiştir.

2.2. Veri Ön İşleme (Preprocessing) Adımları

Ham verilerin doğrudan modele verilmesi, eğitim süresini uzatmakta ve başarıyı düşürmektedir. Bu nedenle görüntüler üzerinde şu işlemler uygulanmıştır: İlk olarak, hesaplama maliyetini düşürmek ve modelin giriş katmanına standart bir veri sağlamak amacıyla tüm görüntüler 224x224 piksel boyutuna yeniden boyutlandırılmıştır. İkinci olarak, piksel değerleri (0-255 arası) 0 ile 1 aralığına normalize edilmiştir. Bu işlem, gradyan iniş algoritmasının daha hızlı yakınsamasını (convergence) sağlar. Son olarak, veri seti bilimsel standartlara uygun olarak; %80 Eğitim (Training), %10 Doğrulama (Validation) ve %10 Test seti olarak ayrılmıştır.

3. YÖNTEM: KONVOLÜSYONEL SİNİR AĞLARI (CNN)

Görüntü sınıflandırma problemi için en uygun mimari olan CNN (Convolutional Neural Networks) tercih edilmiştir. CNN'in seçilmesindeki en temel neden, 'Translation Invariance' özelliğidir; yani sistem, güneşin veya bulutun görüntünün hangi köşesinde olduğundan bağımsız olarak nesneyi tanıyabilir. Ayrıca Yapay Sinir Ağları (ANN) görüntüyü tek boyutlu bir vektöre dönüştürerek mekansal bilgiyi kaybederken, CNN matris yapısını koruyarak piksel komşuluklarını dikkate alır.

Geliştirilen model mimarisi şu katmanlardan oluşmaktadır: Giriş katmanından sonra gelen 'Conv2D' katmanları, görüntü üzerinde filtreler gezdirerek kenar, köşe ve doku gibi özellikleri çıkarır. 'ReLU' aktivasyon fonksiyonu, modelin doğrusallığını kırarak karmaşık problemleri öğrenmesini sağlar. 'MaxPooling' katmanları, görüntünün boyutunu küçülterek işlem yükünü hafifletir ve önemli özellikleri belirginleştirir. Son aşamada ise 'Dropout' katmanı ile nöronların bir kısmı rastgele kapatılarak ezberleme önlenir ve 'Dense' katmanları ile nihai sınıflandırma kararı verilir.

4. BULGULAR VE TARTIŞMA

4.1. Model Eğitim Performansı

Model eğitimi, GPU hızlandırması destekli bir ortamda gerçekleştirilmiştir. Eğitim sürecinde kayıp (loss) fonksiyonu olarak 'Cross Entropy Loss' ve optimizasyon algoritması olarak 'Adam Optimizer' kullanılmıştır. Eğitim ve doğrulama grafikleri incelendiğinde, her iterasyonda (epoch) hata oranının istikrarlı bir şekilde düştüğü ve modelin öğrenme kapasitesinin arttığı gözlemlenmiştir. Eğitim verisi üzerindeki başarı ile doğrulama verisi üzerindeki başarı birbirine paralel ilerlemiş, bu da modelin veriyi ezberlemediğini, gerçekten öğrendiğini kanıtlamıştır.

4.2. Sonuçların Analizi

Test veri seti üzerinde yapılan nihai değerlendirmelerde, modelin genel doğruluk oranının %90'ın üzerinde olduğu tespit edilmiştir. Karmaşıklık matrisi (Confusion Matrix) incelendiğinde, modelin özellikle görsel olarak zıt karakteristikteki 'Güneşli' ve 'Yağmurlu' sınıflarını neredeyse hatasız ayırdığı görülmüştür. Ancak, ışık koşullarının benzer olduğu bazı 'Bulutlu' ve 'Yağmurlu' görüntülerinde çok düşük oranda karışıklık yaşanabildiği, bunun da veri setindeki geçişli hava durumlarından kaynaklandığı değerlendirilmiştir.

5. PROJE DOKÜMANTASYONU VE KULLANIM

Projenin sürdürülebilirliği, geliştirilebilirliği ve tekrar edilebilirliği açısından tüm kaynak kodlar, eğitilmiş model dosyaları ve veri setleri GitHub platformunda profesyonel bir yapıda arşivlenmiştir. Proje dizin yapısı, modüler programlama prensiplerine uygun olarak tasarlanmıştır.

GitHub deposunda bulunan 'train.py' dosyası, modelin sıfırdan eğitilmesini sağlar ve eğitim sonucunda ağırlıkları 'models' klasörüne kaydeder. 'app.py' dosyası ise Gradio kütüphanesini kullanarak kullanıcı dostu bir web arayüzü başlatır. Kullanıcılar bu arayüz üzerinden bilgisayarlarındaki herhangi bir fotoğrafı yükleyerek saniyeler içinde hava durumu analizi yapabilirler. Projenin çalıştırılabilmesi için gerekli tüm kütüphaneler (Torch, Torchvision, Pillow, Gradio) 'requirements.txt' dosyasında listelenmiştir.